

EDA

Exploratory Data Analysis (EDA) merupakan tahap krusial dalam proses pengembangan model machine learning, di mana kita mengeksplorasi dataset untuk memahami struktur, pola, distribusi data, serta potensi isu seperti missing values, outlier, atau ketidakseimbangan kelas. Pada proyek ini, EDA dilakukan menggunakan Python dengan library seperti Pandas, NumPy, Matplotlib, Seaborn, dan Missingno. Dataset yang digunakan adalah "Bank Dataset Additional Full", yang berasal dari UCI Machine Learning Repository dan berfokus pada kampanye pemasaran bank untuk memprediksi apakah klien akan berlangganan deposito berjangka (variabel target: 'y' dengan nilai 'yes' atau 'no'). Dataset ini terdiri dari 41.188 baris dan 21 kolom, mencakup atribut klien, kontak telepon, kampanye sebelumnya, serta konteks sosial-ekonomi.

1. Deskripsi Dataset dan Atribut

Dataset ini mencakup data dari kampanye pemasaran langsung bank Portugal melalui panggilan telepon. Variabel target ('y') menunjukkan apakah klien berlangganan deposito ('yes') atau tidak ('no'). Atribut dibagi menjadi empat kategori utama:

- **Atribut Klien (Client Attributes):**
 - age: Usia klien (numerik, rentang 17-98 tahun).
 - job: Jenis pekerjaan (kategorikal: "admin.", "blue-collar", "entrepreneur", "housemaid", "management", "retired", "self-employed", "services", "student", "technician", "unemployed", "unknown").
 - marital: Status pernikahan (kategorikal: "divorced", "married", "single", "unknown").
 - education: Tingkat pendidikan (kategorikal: "basic.4y", "basic.6y", "basic.9y", "high.school", "illiterate", "professional.course", "university.degree", "unknown").
 - default: Apakah memiliki kredit macet? (kategorikal: "no", "yes", "unknown").
 - housing: Apakah memiliki pinjaman rumah? (kategorikal: "no", "yes", "unknown").
 - loan: Apakah memiliki pinjaman pribadi? (kategorikal: "no", "yes", "unknown").
- **Atribut Kontak Telepon Terakhir (Last Telephone Contact):**
 - contact: Jenis komunikasi (kategorikal: "cellular", "telephone").
 - month: Bulan kontak terakhir (kategorikal: "jan", "feb", ..., "dec").
 - day_of_week: Hari kontak terakhir (kategorikal: "mon", "tue", "wed", "thu", "fri").
 - duration: Durasi kontak terakhir dalam detik (numerik). Catatan: Variabel ini sangat memengaruhi target, tetapi sebaiknya diabaikan untuk model prediksi realistis karena durasi hanya diketahui setelah panggilan selesai.


- **Atribut Lainnya (Other Attributes):**
 - campaign: Jumlah kontak selama kampanye ini (numerik, termasuk kontak terakhir).
 - pdays: Jumlah hari sejak kontak terakhir dari kampanye sebelumnya (numerik; 999 berarti belum pernah dikontak).
 - previous: Jumlah kontak sebelum kampanye ini (numerik).
 - poutcome: Hasil kampanye sebelumnya (kategorikal: "failure", "nonexistent", "success").
- **Atribut Konteks Sosial-Ekonomi (Social and Economic Context):**
 - emp.var.rate: Tingkat variasi pekerjaan (numerik, indikator triwulanan).
 - cons.price.idx: Indeks harga konsumen (numerik, indikator bulanan).
 - cons.conf.idx: Indeks kepercayaan konsumen (numerik, indikator bulanan).
 - euribor3m: Tingkat Euribor 3 bulan (numerik, indikator harian).
 - nr.employed: Jumlah karyawan (numerik, indikator triwulanan).

2. Overview Dataset

- Jumlah Baris dan Kolom: 41.188 baris dan 21 kolom.
- Tipe Data: 10 kolom numerik (5 int64, 5 float64) dan 11 kolom kategorikal (object).
 - Numerik (10 fitur): age, duration, campaign, pdays, previous, emp.var.rate, cons.price.idx, cons.conf.idx, euribor3m, nr.employed .
 - Kategorikal (10 fitur): job, marital, education, default, housing, loan, contact, month, day_of_week, poutcome.
 - Target (Label): Kolom y yang berisi nilai "yes" (berlangganan) atau "no" (tidak).
- Nilai Unik: Variabel seperti duration memiliki 1.544 nilai unik, sementara y hanya 2 ('yes', 'no').
- Missing Values: Tidak ada missing values di seluruh kolom (df.isnull().sum() = 0 untuk semua kolom). Ini menunjukkan dataset sudah bersih dari segi kelengkapan data, sehingga tidak diperlukan imputasi.

3. Histogram Distribusi Variabel Numerik

Visualisasi ini dibuat menggunakan sns.histplot dengan Kernel Density Estimation (KDE) untuk menampilkan distribusi frekuensi variabel numerik.



- Deskripsi dan Interpretasi:

- Age: Distribusi skewed ke kanan (right-skewed), dengan puncak frekuensi sekitar 30-40 tahun. Mayoritas klien berusia 20-60 tahun, dengan sedikit outlier di atas 80 tahun. Ini menunjukkan dataset didominasi oleh usia dewasa muda hingga paruh baya.
- Duration: Sangat skewed ke kanan, puncak di sekitar 0-200 detik, dengan tail panjang hingga 5000 detik. Banyak panggilan singkat, menandakan sebagian besar interaksi tidak berhasil atau cepat berakhir.
- Campaign: Skewed ke kanan, mayoritas 1-5 kontak, puncak di 1-2. Jarang ada lebih dari 10 kontak, menunjukkan kampanye tidak terlalu agresif.
- Pdays: Distribusi bimodal dengan spike besar di 999 (artinya "belum pernah dikontak"), dan sedikit nilai rendah. Ini mengindikasikan sebagian besar klien adalah prospek baru.
- Previous: Mayoritas di 0, skewed ke kanan dengan nilai kecil (maks 7). Sedikit klien yang pernah dikontak sebelumnya.

- Emp.var.rate: Multimodal dengan puncak di sekitar -2, 1, dan 1.4, mencerminkan variasi ekonomi periode waktu berbeda.
- Cons.price.idx: Multimodal, puncak di sekitar 93.000-94.000, menunjukkan fluktuasi indeks harga.
- Cons.conf.idx: Agak normal, puncak di -40 hingga -42, dengan rentang -50 hingga -30.
- Euribor3m: Multimodal, puncak di 1 dan 5, mencerminkan tingkat suku bunga yang bervariasi.
- Nr.employed: Multimodal, puncak di 5100-5200, menunjukkan indikator ketenagakerjaan yang stabil tapi dengan cluster.
- Insight: Banyak variabel skewed, sehingga transformasi (e.g., log scaling) mungkin diperlukan untuk modeling. Outlier pada duration dan campaign perlu ditangani (e.g., capping). Variabel ekonomi (emp.var.rate, euribor3m, dll.) menunjukkan pola multimodal, mungkin terkait dengan siklus ekonomi.
- Implikasi untuk ML: Distribusi skewed dapat memengaruhi model seperti regresi linear; gunakan normalisasi atau robust scaler. Variabel seperti pdays dengan nilai dominan (999) bisa diubah menjadi fitur biner (e.g., "previously_contacted").

4. Temuan Analisis Eksploratif (EDA Insight)

A. Analisis Target (Imbalance Data)

Distribusi variabel target y sangat tidak seimbang (imbalanced). Mayoritas nasabah menolak tawaran deposito.

- No: ~36.548 data (88.7%).
- Yes: ~4.640 data (11.3%).

Model harus menggunakan teknik penanganan imbalance seperti SMOTE, Random Undersampling, atau menggunakan parameter class_weight saat pelatihan.

B. Wawasan Variabel Numerik

- Durasi Telepon (duration): Terdapat catatan penting bahwa fitur ini sangat mempengaruhi target (jika durasi=0, maka y="no"). Namun, nilai durasi tidak diketahui sebelum panggilan dilakukan. Oleh karena itu, fitur ini harus dibuang untuk pembuatan model prediktif yang realistis.
- Hari Berlalu (pdays): Mayoritas data bernilai 999, yang berarti nasabah tersebut belum pernah dihubungi sebelumnya.
- Multikolinearitas (Korelasi Tinggi): Berdasarkan heatmap, ditemukan korelasi yang sangat kuat antar indikator ekonomi:
- emp.var.rate berkorelasi sangat kuat dengan nr.employed (0.91) dan euribor3m (0.97).

C. Wawasan Variabel Kategorikal

1. Pekerjaan (job): Profesi terbanyak adalah admin. (25.3%), diikuti blue-collar (22.5%). Namun, rasio keberhasilan (conversion rate) mungkin lebih tinggi pada student atau retired (perlu verifikasi visualisasi).

2. Pendidikan (education): Sebagian besar nasabah memiliki gelar universitas (university.degree - 29.5%).
3. Kontak (contact): Penggunaan telepon seluler (cellular) jauh lebih dominan dibandingkan telepon rumah dan umumnya memiliki tingkat respon positif yang lebih baik.
4. Bulan (month): Bulan Mei (may) memiliki jumlah kontak terbanyak tetapi tingkat keberhasilannya cenderung rendah. Bulan-bulan seperti Maret, September, Oktober, dan Desember memiliki volume rendah tapi rasio keberhasilan lebih tinggi.

Preprocessing & Feature Engineering

Pipeline Preprocessing & Feature Engineering Proses ini mempersiapkan data yang bersih dan terstruktur dengan baik untuk pengembangan model pembelajaran mesin.

- Penanganan Data Leakage

Fitur yang dihapus fitur "duration"

Nilai durasi panggilan (duration) hanya diketahui setelah panggilan berakhir. Jika durasi = 0, maka output target y pasti 'no'. Menggunakan fitur ini akan menyebabkan data leakage dan membuat model bias (tidak realistis untuk prediksi real-time).

- Penanganan Nilai yang hilang ('Unknown')

menggunakan metode Imputasi modus untuk fitur kategorikal (mengisi nilai yang hilang (missing values) dalam data dengan menggunakan nilai yang paling sering muncul (modus) fitur yang terpengaruh

Fitur	Jumlah Unknown	Nilai Imputasi
job	330	'admin.'
marital	80	'married'
education	1731	'university.degree'
default	8597	'no'
housing	990	'yes'
loan	990	'no'

Imputasi modus dipilih sebagai metode yang sederhana dan efektif dengan asumsi adalah nilai yang tidak diketahui kemungkinan mengikuti distribusi dari kelas mayoritas

- Feature Engineering

Transformasi fitur 'pdays'

original 'pdays' = 999 berarti klien tidak pernah dihubungi sebelumnya

fitur baru 'pernah_dihubungi' (binary 0/1)

- 0 = tidak pernah dihubungi
- 1 = pernah dihubungi

indikator binary lebih mudah diinterpretasi dan informatif untuk model dibandingkan nilai 999

- Encoding variabel target
Transformasi:
 - 'yes' = 1 (klien berlangganan)
 - 'no' = 0 (klien tidak berlangganan)
- Encoding fitur kategorikal (One hot encoding)

One-hot encoding dengan drop_first=True mencegah multikolinearitas sambil memungkinkan model untuk belajar dari variabel kategorikal.

Fitur yang di encoding

job, marital, education, default, housing, loan, contact, month, day_of_week, outcome

struktur fitur dataset final setelah di encoding

Tipe Data	Jumlah Kolom	Daftar Fitur	Deskripsi
Numerik	8	age, campaign, previous, emp.var.rate, cons.price.idx, cons.conf.idx, euribor3m, nr.employed	Fitur angka kontinu yang dipertahankan.
Biner (Derived)	1	pernah_dihubungi	Fitur baru hasil transformasi dari pdays. (1=Pernah, 0=Belum).
Biner (One-hot)	37	job, marital, education, default, housing, loan, contact, month, day_of_week, poutcome_*	Variabel dummy hasil encoding (nilai 0 atau 1).
Target	1	y	Label klasifikasi biner.

Modeling

Pada tahap pemodelan, seluruh library yang diperlukan untuk proses analisis data, pemodelan, evaluasi, dan penyimpanan model pertama-tama diimpor, termasuk pandas, numpy, XGBoost, scikit-learn, imblearn, seaborn, matplotlib, serta joblib. Dataset yang telah melalui proses pembersihan sebelumnya kemudian dimuat kembali, dengan total 41.188 observasi dan 47 variabel prediktor.

RangeIndex: 41188 entries, 0 to 41187

Data columns (total 47 columns):

```
# Column Non-Null Count Dtype
---  ---
0 age 41188 non-null int64
```

1	campaign	41188 non-null int64
2	previous	41188 non-null int64
3	emp.var.rate	41188 non-null float64
4	cons.price.idx	41188 non-null float64
5	cons.conf.idx	41188 non-null float64
6	euribor3m	41188 non-null float64
7	nr.employed	41188 non-null float64
8	pernah_dihubungi	41188 non-null int64
9	job_blue-collar	41188 non-null int64
10	job_entrepreneur	41188 non-null int64
11	job_housemaid	41188 non-null int64
12	job_management	41188 non-null int64
13	job_retired	41188 non-null int64
14	job_self-employed	41188 non-null int64
15	job_services	41188 non-null int64
16	job_student	41188 non-null int64
17	job_technician	41188 non-null int64
18	job_unemployed	41188 non-null int64
19	marital_married	41188 non-null int64
20	marital_single	41188 non-null int64
21	education_basic.6y	41188 non-null int64
22	education_basic.9y	41188 non-null int64
23	education_high.school	41188 non-null int64
24	education_illiterate	41188 non-null int64
25	education_professional.course	41188 non-null int64
26	education_university.degree	41188 non-null int64
27	default_yes	41188 non-null int64
28	housing_yes	41188 non-null int64
29	loan_yes	41188 non-null int64
30	contact_telephone	41188 non-null int64
31	month_aug	41188 non-null int64
32	month_dec	41188 non-null int64
33	month_jul	41188 non-null int64
34	month_jun	41188 non-null int64
35	month_mar	41188 non-null int64
36	month_may	41188 non-null int64
37	month_nov	41188 non-null int64
38	month_oct	41188 non-null int64
39	month_sep	41188 non-null int64
40	day_of_week_mon	41188 non-null int64
41	day_of_week_thu	41188 non-null int64
42	day_of_week_tue	41188 non-null int64
43	day_of_week_wed	41188 non-null int64
44	poutcome_nonexistent	41188 non-null int64
45	poutcome_success	41188 non-null int64
46	y	41188 non-null int64

dtypes: float64(5), int64(42)

Fitur dan target dipisahkan, kemudian dilakukan normalisasi pada delapan fitur numerik menggunakan StandardScaler agar skala nilai lebih seragam dan mencegah dominasi fitur dengan rentang nilai besar. Proses pembagian data dilakukan menggunakan train–test split dengan rasio 80:20 serta parameter stratify untuk menjaga proporsi kelas pada data latih dan uji.

```
Bentuk X_train: (32950, 46)
Bentuk X_test: (8238, 46)

Proporsi 'y' di y_train:
y
0    0.887344
1    0.112656
Name: proportion, dtype: float64

Proporsi 'y' di y_test:
y
0    0.887351
1    0.112649
Name: proportion, dtype: float64
```

Untuk mengatasi ketidakseimbangan kelas, dihitung nilai `scale_pos_weight` berdasarkan rasio jumlah kelas mayoritas terhadap kelas minoritas, yaitu sebesar 7.88, dan nilai ini diimplementasikan dalam model XGBoost agar meningkatkan penalti terhadap kesalahan prediksi kelas minoritas.

```
# --- 1. Hitung scale_pos_weight ---
counter = y_train.value_counts()
scale_pos_weight_value = counter[0] / counter[1]
print(f"Menggunakan scale_pos_weight: {scale_pos_weight_value:.2f}")
```

Selanjutnya dilakukan hyperparameter tuning menggunakan RandomizedSearchCV pada model XGBoost. Proses ini melibatkan ruang pencarian parameter yang luas, seperti jumlah pohon (`n_estimators`), kedalaman tree (`max_depth`), learning rate, subsample, `colsample_bytree`, `gamma`, dan `min_child_weight`.

```
# --- 2. Konfigurasi Hyperparameter Tuning ---
print("\n--- Memulai Hyperparameter Tuning (RandomizedSearchCV) ---")

# Model dasar
xgb_model = xgb.XGBClassifier(
    objective='binary:logistic',
    eval_metric='logloss',
    use_label_encoder=False,
    scale_pos_weight=scale_pos_weight_value,
    random_state=42,
    n_jobs=-1
)

# Grid Parameter yang akan diuji
param_dist = {
    'n_estimators': [100, 200, 300, 400, 500],
    'max_depth': [3, 4, 5, 6, 7, 8],
    'learning_rate': [0.01, 0.05, 0.1, 0.2],
    'subsample': [0.7, 0.8, 0.9, 1.0],
    'colsample_bytree': [0.7, 0.8, 0.9, 1.0],
    'gamma': [0, 0.1, 0.2, 0.3],
    'min_child_weight': [1, 3, 5, 7]
}

# Scorer: Fokus optimasi pada F1-score untuk kelas 1 (positif)
f1_scorer_class1 = make_scorer(f1_score, pos_label=1)

# Inisialisasi RandomizedSearchCV
random_search = RandomizedSearchCV(
    estimator=xgb_model,
    param_distributions=param_dist,
    n_iter=50,
    scoring=f1_scorer_class1,
    cv=5,
    n_jobs=-1,
    random_state=42,
    verbose=1
)
```

Tuning dijalankan sebanyak 50 iterasi dengan 5-fold cross-validation, dan metrik yang dioptimalkan adalah F1-score untuk kelas 1 sebagai fokus peningkatan performa pada kelas minoritas.

Model terbaik dari hasil tuning kemudian dievaluasi menggunakan data uji. Hasil evaluasi menunjukkan bahwa model memiliki akurasi sebesar 0.8587. Confusion matrix memperlihatkan kemampuan model yang baik dalam mengenali kelas mayoritas, namun tetap mempertahankan recall yang cukup tinggi untuk kelas minoritas sebesar 0.64. Meskipun precision untuk kelas 1 masih moderat pada nilai 0.42, F1-score kelas minoritas mencapai 0.51, menunjukkan keseimbangan antara recall yang tinggi dan precision yang relatif rendah. Secara keseluruhan, model mampu menangani ketidakseimbangan kelas dengan cukup baik melalui kombinasi `scale_pos_weight` dan tuning hyperparameter.

```
*** Menggunakan scale_pos_weight: 7.88
--- Memulai Hyperparameter Tuning (RandomizedSearchCV) ---
Fitting 5 folds for each of 50 candidates, totalling 250 fits

--- Tuning Selesai ---
Skor F1 (kelas 1) terbaik CV: 0.4820
Parameter terbaik: {'subsample': 0.7, 'n_estimators': 200, 'min_child_weight': 5, 'max_depth': 8, 'learning_rate': 0.01, 'gamma': 0.2, 'colsample_bytree': 0.8}

--- Hasil Evaluasi Model Terbaik ---
Accuracy: 0.8587

Confusion Matrix:
[[6476  834]
 [ 330 598]]

Classification Report:

```

	precision	recall	f1-score	support
0	0.95	0.89	0.92	7310
1	0.42	0.64	0.51	928
accuracy			0.86	8238
macro avg	0.68	0.77	0.71	8238
weighted avg	0.89	0.86	0.87	8238

Analisis lebih lanjut dilakukan dengan mengekstraksi feature importance dari model XGBoost terbaik. Hasilnya menunjukkan bahwa variabel `nr.employed`, `emp.var.rate`, variabel waktu seperti `month_may`, serta fitur perilaku kampanye seperti `pernah_dihubungi` memiliki kontribusi paling besar terhadap proses prediksi. Selain itu, fitur-fitur terkait kondisi ekonomi makro seperti `cons.conf.idx`, `cons.price.idx`, dan `euribor3m` juga memberikan pengaruh yang signifikan.

